In [ ]:
```python
import base64
# Função para converter a imagem em código Base64
def get_image_base64(path):
    with open(path, "rb") as image_file:
        encoded_string = base64.b64encode(image_file.read()).decode('utf-8')
    return f"{encoded_string}"

# Carrega o banner de forma imutável para o export
img_path = "reports/figures/banner_heineken.png"

if os.path.exists(img_path):
    banner_executivo = mo.image(
        src=get_image_base64(img_path),
        alt="Banner Dossiê Heineken",
        width="100%",
        rounded=True
    )
else:
    banner_executivo = mo.md("**Erro:** Banner não encontrado em `reports/fi

banner_executivo
```

🎯 Dossiê Executivo: Otimização de Pricing e Elasticidade de Cesta

```
**Projeto:** Auditoria de Repasse de Custo - Heineken LN
330ml
**Metodologia:** CRISP-DM (Cross-Industry Standard Process
for Data Mining)

---

## 1. O Contexto de Negócio (A Dor da Margem)
A indústria notificou a nossa rede sobre um aumento no custo
de reposição da **Heineken Long Neck 330ml**, passando de
**R$ 5,00 para R$ 5,50**.

A resposta imediata (e instintiva) da operação comercial foi
sugerir o repasse integral desse aumento para o consumidor
final, subindo o preço de gôndola de **R$ 6,50 para R$
7,20**. O objetivo dessa manobra seria proteger a margem
percentual do setor de Bebidas.
```

```
## 2. O Risco Estratégico (O "Ponto Cego" do Varejo)


A Heineken não é um produto comum; ela é um **KVI (Key Value
Item - Item Notável)**. Ela pertence à Curva A+ da loja e
possui altíssima sensibilidade a preço. O cliente tem o valor
de R$ 6,50 memorizado.

O risco crítico que este laboratório visa auditar é o
conceito de **Loss Leader (Isca de Tráfego)**:
* Se o cliente achar a cerveja cara, ele irá para o
concorrente.
* Se ele for para o concorrente, perderemos apenas os
centavos da margem da cerveja, ou perderemos o **lucro
inteiro do Açougue** (Picanha, Carvão e Gelo) que ele
compraria junto?

## 3. O Objetivo da Auditoria (Critério SMART)
Em vez de tomar decisões baseadas na intuição (feeling) do
comprador, este laboratório utiliza Engenharia de Dados de
alta performance (**Polars**) e Machine Learning (**Regressão
Linear**) para:
1. Simular o impacto financeiro real do aumento de preço no
caixa diário.
2. Realizar uma **Análise de Cesta de Compras (Market Basket
Analysis)** para medir a Taxa de Anexo (Attach Rate) da
cerveja com produtos perecíveis.
3. Calcular a **Elasticidade Cruzada**, provando
matematicamente quantos reais o Açougue perde a cada R$ 1,00
que a Bebida sobe.

A seguir, o detalhamento técnico, o processamento dos logs de
PDV e a decisão executiva final para a operação.
```

In [ ]:
```python
import polars as pl
import numpy as np
import marimo as mo
import os
```

Quinzena 1: Preço a R$ 6.50

In [ ]:
```python
np.random.seed(42)
df_preco_antigo = pl.DataFrame({
    "Preco_Venda_R$":[6.50] * 15,
    "Custo_Unitario_R$":[5.50] * 15,
    "Volume_Vendido": np.random.normal(120,15,15).astype(int)
})
```

Quinzena 2: Preço a R$ 7.20 (Repasse de aumento)

In [ ]:
```
df_preco_novo = pl.DataFrame({
    "Preco_Venda_R$":[7.20] * 15,
    "Custo_Unitario_R$":[5.50] * 15,
    "Volume_Vendido": np.random.normal(75,12,15).astype(int)
})
```

In [ ]:
```
df_pdv_heineken = pl.concat([df_preco_antigo,df_preco_novo])
```

In [ ]:
```
caminho_raw = "data/raw"
os.makedirs(caminho_raw, exist_ok=True)
arquivo_csv = f"{caminho_raw}/pdv_heineken_30dias.csv"
df_pdv_heineken.write_csv(arquivo_csv)
```

🔒 Governança de Dados Concluída

O arquivo físico de auditoria foi gerado e salvo com sucesso no cofre: `{arquivo_csv}`. A nossa base bruta de operações agora está protegida e pronta para a modelagem financeira.

Extração

In [ ]:
```
caminho_arquivo = "data/raw/pdv_heineken_30dias.csv"
df_raw = pl.read_csv(caminho_arquivo)
df_raw
```

Preco_Venda_R$ f64	Custo_Unitario_R$ f64	Volume_Vendido i64
6,5	5,5	127
6,5	5,5	117
6,5	5,5	129
6,5	5,5	142
6,5	5,5	116
6,5	5,5	116
6,5	5,5	143
6,5	5,5	131
6,5	5,5	112
6,5	5,5	128

30 rows, 3 columns

Transformação

In [ ]:
```
df_financeiro = df_raw.with_columns(
    (pl.col("Preco_Venda_R$") * pl.col("Volume_Vendido")).alias("Faturamento
    (pl.col("Custo_Unitario_R$") * pl.col("Volume_Vendido")). alias("Custo_T
).with_columns(
```

```
    (pl.col("Faturamento_R$") - pl.col("Custo_Total_R$")).alias("Lucro_Bruto
)
df_financeiro
```

Preco_Venda_R$ f64	Custo_Unitario_R$ f64	Volume_Vendido i64	Faturamento_R$ f64	Custo_Total_R$ f64	Lucro_Bruto_R$ f64
6,5	5,5	127	825,5	698,5	127
6,5	5,5	117	760,5	643,5	117
6,5	5,5	129	838,5	709,5	129
6,5	5,5	142	923	781	142
6,5	5,5	116	754	638	116
6,5	5,5	116	754	638	116
6,5	5,5	143	929,5	786,5	143
6,5	5,5	131	851,5	720,5	131
6,5	5,5	112	728	616	112
6,5	5,5	128	832	704	128

30 rows, 6 columns

Modegem

In [ ]:
```
df_resultado = (
    df_financeiro.group_by("Preco_Venda_R$").agg(
        pl.col("Volume_Vendido").sum().alias("Total_Garrafas_Vendidas"),
        pl.col("Faturamento_R$").sum().round(2).alias("Faturamento_Total_R$"
        pl.col("Lucro_Bruto_R$").sum().round(2).alias("Lucro_Bruto_Total_R$"
    ).sort("Preco_Venda_R$")
)
df_resultado
```

Preco_Venda_R$ f64	Total_Garrafas_Vendidas i64	Faturamento_Total_R$ f64	Lucro_Bruto_Total_R$ f64
6,5	1.795	11.667,5	1.795
7,2	1.048	7.545,6	1.781,6

2 rows, 4 columns

Considerando que o fabricante elevou o preço a 5.50

- cenario 1 = 6.50
- cenario 2 - 7.20

In [ ]:
```
lucro_6_50 = (6.50 - 5.50) * 1795
lucro_6_50
```

1795.0

In [ ]:
```
lucro_7_20 = (7.20 - 5.50) * 1781
lucro_7_20
```

3027.7000000000003

In [ ]:
```
np.random.seed(42)
n_cupons = 5000
```

```
cupons_heineken = np.arange(1, int(n_cupons * 0.3) + 1)
dados_pdv = []
for cupom in range(1, n_cupons + 1):
    # Todo cliente compra o básico
    dados_pdv.append({"Cupom_ID": cupom, "Produto": "Pao Frances 1KG", "Lucr

    # Se o cliente é do grupo que comprou Heineken...
    if cupom in cupons_heineken:
        dados_pdv.append({"Cupom_ID": cupom, "Produto": "Heineken LN 330ml",

        # O comportamento âncora: 70% de chance de levar itens de churrasco
        if np.random.rand() > 0.3:
            dados_pdv.append({"Cupom_ID": cupom, "Produto": "Picanha Maturac
            dados_pdv.append({"Cupom_ID": cupom, "Produto": "Carvao Eucalipt
            dados_pdv.append({"Cupom_ID": cupom, "Produto": "Gelo Filtrado 5

df_cupons_brutos = pl.DataFrame(dados_pdv)
df_cupons_brutos
```

Cupom_ID i64	Produto str unique: 5	Lucro_R$ f64
1	Pao Frances 1KG	2,5
1	Heineken LN 330ml	1
1	Picanha Maturada a Vácuo	25
1	Carvao Eucalipto 3KG	8,5
1	Gelo Filtrado 5KG	4
2	Pao Frances 1KG	2,5
2	Heineken LN 330ml	1
2	Picanha Maturada a Vácuo	25
2	Carvao Eucalipto 3KG	8,5
2	Gelo Filtrado 5KG	4

9.602 rows, 3 columns

In [ ]:

```
# Passo A: Quais cupons tem Heineken? (Isolando a isca)
ids_com_heineken = (
    df_cupons_brutos
    .filter(pl.col("Produto") == "Heineken LN 330ml")
    .select("Cupom_ID")
)

# Passo B: Pegar TODOS os produtos que estavam DENTRO desses mesmos cupons (
df_cesta_completa = df_cupons_brutos.join(ids_com_heineken, on="Cupom_ID", h

# Passo C: Tirar a Heineken da lista para ver apenas o "Lucro Indireto" dos
df_acompanhantes = df_cesta_completa.filter(pl.col("Produto") != "Heineken L

# Passo D: Calcular a frequência e o Lucro Indireto Total gerado pela âncora
df_analise_cesta = (
    df_acompanhantes.group_by("Produto")
    .agg(
        pl.col("Cupom_ID").count().alias("Vezes_Comprado_Junto"),
        pl.col("Lucro_R$").sum().round(2).alias("Lucro_Indireto_Gerado_R$")
    )
    .sort("Lucro_Indireto_Gerado_R$", descending=True)
)
df_analise_cesta
```

Produto str	Vezes_Comprado_Junto u32	Lucro_Indireto_Gerado_R$ f64
Picanha Maturada a Vácuo	1.034	25.850
Carvao Eucalipto 3KG	1.034	8.789
Gelo Filtrado 5KG	1.034	4.136
Pao Frances 1KG	1.500	3.750

4 rows, 3 columns

In [ ]:
```
from sklearn.linear_model import LinearRegression

# ==========================================
# 1. ETL: DADOS HISTÓRICOS (Preço Cerveja vs Venda Picanha)
# ==========================================
np.random.seed(42)
dias = 60

# Simulamos flutuações de preço da Heineken entre R$ 6.00 e R$ 8.00 ao longo
preco_heineken_hist = np.random.uniform(6.00, 8.00, dias)

# A regra de negócio embutida: Quanto mais cara a cerveja, menos picanha sai
# Volume Base = 150 peças. A cada R$ 1 na cerveja, perdemos em média 12 peça
venda_picanha_hist = 150 - (12 * preco_heineken_hist) + np.random.normal(0,

df_hist = pl.DataFrame({
    "Preco_Heineken_R$": preco_heineken_hist,
    "Volume_Picanha": venda_picanha_hist.astype(int)
})

# ==========================================
# 2. MODELAGEM PREDITIVA (Regressão Linear - CRISP-DM Fase 3)
# ==========================================
# Separando a variável preditora (X) e a variável alvo (y)
X = df_hist["Preco_Heineken_R$"].to_numpy().reshape(-1, 1)
y = df_hist["Volume_Picanha"].to_numpy()

# Treinando o cérebro da máquina
modelo = LinearRegression()
modelo.fit(X, y)

# O modelo descobriu a sensibilidade!
# modelo.coef_[0] nos diz quantas carnes perdemos por cada R$ 1,00 de aument

# ==========================================
# 3. TESTE DE CENÁRIOS (What-If Analysis)
# ==========================================
# Simulando o impacto dos nossos dois preços
cenarios_preco = np.array([[6.50], [7.20]])
previsao_picanha = modelo.predict(cenarios_preco).astype(int)

df_cenarios = pl.DataFrame({
    "Cenario_Preco_Heineken_R$": [6.50, 7.20],
    "Previsao_Venda_Picanha_Qtd": previsao_picanha
}).with_columns(
    # A Picanha nos dá R$ 25,00 de lucro limpo por peça
    (pl.col("Previsao_Venda_Picanha_Qtd") * 25.00).alias("Lucro_Projetado_Pi
)
```

```
# Calculando a perda absoluta entre os dois cenários
lucro_baixo = df_cenarios.filter(pl.col("Cenario_Preco_Heineken_R$") == 7.20
lucro_alto = df_cenarios.filter(pl.col("Cenario_Preco_Heineken_R$") == 6.50)
perda_financeira = lucro_alto - lucro_baixo

# ==========================================
# 4. APRESENTAÇÃO GERENCIAL (MARIMO NATIVO)
# ==========================================
painel_ia = mo.vstack([
    mo.md("""
    ### 🤖 IA de Pricing: Regressão Linear de Elasticidade Cruzada

    O modelo de Machine Learning analisou 60 dias de histórico e encontrou a

    **Resultados da Projeção Diária:**
    """),

    # Passamos o DataFrame solto. O Marimo renderiza a tabela perfeita autom
    df_cenarios,

    mo.md(f"""
    🚨 **ALERTA DE ROMBO NO AÇOUGUE:** A Regressão Linear prova que, ao subi
    """)
])

# Retornando a variável no final da célula para exibir na tela
painel_ia
```

🤖 IA de Pricing: Regressão Linear de Elasticidade Cruzada

O modelo de Machine Learning analisou 60 dias de histórico e encontrou a correlação matemática exata entre o preço da cerveja e a venda da carne.

Resultados da Projeção Diária:

Cenario_Preco_Heineken_R$ f64	Previsao_Venda_Picanha_Qtd i64	Lucro_Projetado_Picanha_R$ f64
6,5	71	1.775
7,2	62	1.550

2 rows, 3 columns

🚨 **ALERTA DE ROMBO NO AÇOUGUE:** A Regressão Linear prova que, ao subirmos a Heineken para R$ 7.20, nós perderemos **R$ 225.00 por dia** APENAS no lucro da Picanha. Isso destrói qualquer ganho de centavos que teríamos na margem da cerveja.

- O Cenário 1 (A Isca Funcionando - Preço a R $6,50) : AInteligênciaArtificialpreviuque, comacervejabarataatraindoclient$ $: 71carnes$ \times$R$ 25,00 = R$ 1.775,00 de lucro no Açougue.
- O Cenário 2 (A Isca Quebrada - Preço a R $7,20) : AIApreviuqueoclienteachouacervejacaraefoiparaaconcorrência. Co$ $: 62carnes$ \times$R$ 25,00 = R $1.550,00delucronoAçougue. OVereditoFinal(ADiferença) : R$ 1.775,00 (Cenário Bom) - R$1.550,00(CenárioRuim) = R$ 225,00.

"Senhores diretores, ao tentarmos proteger alguns centavos de margem na cerveja subindo o preço para R $7,20, nós causamos uma fuga de fluxo na loja. Essa fuga na ç as de Picanha por dia (de 71 caiu para 62). Como a picanha é perder essas 9 vendas significa tirar R$ 225,00 de dinheiro vivo do nosso caixa diário. A cerveja deve continuar a R$ 6,50 para proteger o lucro do Açougue."

In [ ]:

```
# ==========================================
# GERAÇÃO DO DOSSIÊ TÉCNICO E EXECUTIVO (CRISP-DM: DEPLOYMENT)
# ==========================================

dossie_final = mo.md(
    """
    # 📑 Dossiê Técnico e Executivo: Otimização de Pricing KVI (Heineken LN)
    **Área:** Inteligência Comercial & Data Science
    **Stack Tecnológica:** Python, Polars, Scikit-Learn, Marimo, UV (Cookiec

    ---

    ## 1. Entendimento do Negócio (A Dor)
    A indústria repassou um aumento de custo de R$ 5,00 para R$ 5,50 no proc

    ## 2. Arquitetura e Engenharia de Dados (ETL)
    O projeto foi estruturado sob rigorosa governança de dados:
    * **Fundação:** Utilização do *Cookiecutter Data Science* com gerenciado
    * **Extração e Cofre:** Geração de um simulador de PDV (`np.random.norma

    ### 🚧 Trincheiras do Código (Lições Aprendidas na Operação):
    Durante a engenharia de dados, enfrentamos e superamos atritos reais de
    1. **Sintaxe de Módulos:** O erro `TypeError: 'module' object is not cal
    2. **Tipagem de Dados em Python:** A compreensão de que a sintaxe `[6.50
    3. **Case Sensitivity e Governança:** O colapso do `pl.concat` (ShapeErr

    ## 3. Modelagem Analítica e a Visão Estratégica
    O primeiro cruzamento de dados revelou que o aumento para R$ 7,20, avali

    **O Ponto de Virada (Market Basket Analysis):**
    A análise não parou na margem do item. Foi levantada a hipótese de compo

    ## 4. Inteligência Artificial e Veredito (O Risco de R$ 225/dia)
    Para quantificar o risco de ruptura de fluxo, implantamos um modelo prec

    **A Matemática do Chão de Loja:**
    * A IA provou que a cada aumento no preço da cerveja, perdemos volume de
    * Cenário A (Cerveja a R$ 6,50): Previsão de venda de 71 peças de Picanh
    * Cenário B (Cerveja a R$ 7,20): Fuga de clientes derruba a venda para 6
    * **O Rombo:** A diferença entre os cenários resultou em uma perda proje

    ### 🎯 A Ordem Executiva
```

```
    **A etiqueta da Heineken LN deve ser mantida a R$ 6,50.** O varejo não v
    """
)

# Exibindo o relatório na tela do Marimo
dossie_final
```

📑 Dossiê Técnico e Executivo: Otimização de Pricing KVI (Heineken LN)

Área: Inteligência Comercial & Data Science **Stack Tecnológica:** Python, Polars, Scikit-Learn, Marimo, UV (Cookiecutter)

---

1. Entendimento do Negócio (A Dor)

A indústria repassou um aumento de custo de R$5,00 para R$ 5,50 no produto Curva A+ (Heineken LN 330ml). O instinto inicial da operação foi repassar o custo ao cliente (R$ 7,20) para proteger a margem percentual. O objetivo deste projeto foi validar matemati
6,50 ou R$ 7,20) maximiza o Lucro Bruto Absoluto da loja.

2. Arquitetura e Engenharia de Dados (ETL)

O projeto foi estruturado sob rigorosa governança de dados:

- **Fundação:** Utilização do *Cookiecutter Data Science* com gerenciador `uv` para isolamento de dependências, prevenindo dívida técnica.
- **Extração e Cofre:** Geração de um simulador de PDV (`np.random.normal`) para 30 dias de operação, com a trava de aleatoriedade (`seed=42`) para garantir 100% de reprodutibilidade em auditorias. O arquivo bruto foi isolado fisicamente em `data/raw/pdv_heineken_30dias.csv`.

🚧 Trincheiras do Código (Lições Aprendidas na Operação):

Durante a engenharia de dados, enfrentamos e superamos atritos reais de integração de sistemas:

1. **Sintaxe de Módulos:** O erro `TypeError: 'module' object is not callable` ao tentar usar `np.random(42)`. A correção reforçou o uso correto dos métodos internos (`np.random.seed(42)`).
2. **Tipagem de Dados em Python:** A compreensão de que a sintaxe `[6.50] * 15` em Python não representa um cálculo de margem percentual, mas sim a replicação de uma variável em lista ao longo de 15 dias para simular a etiqueta de preço estática na gôndola.
3. **Case Sensitivity e Governança:** O colapso do `pl.concat` (ShapeError) devido a uma divergência de capitalização (`Preco_Venda_R$` vs `Preco_venda_R$`). O rigor do **Polars** bloqueou a concatenação, prevenindo que um dado sujo corrompesse o cálculo final.

3. Modelagem Analítica e a Visão Estratégica

O primeiro cruzamento de dados revelou que o aumento para R$ 7,20, avaliando o produto de forma isolada, traria maior lucro por unidade devido à queda de custo de reposição. **O Ponto de Virada (Market Basket Analysis):** A análise não parou na margem do item. Foi levantada a hipótese de comportamento de compra cruzada. Ao analisarmos o *Attach Rate* (Taxa de Anexo), os dados provaram que a Heineken é um produto **KVI (Isca de Tráfego)**. Clientes que compram a cerveja a R$ 6,50 têm alta probabilidade de ancorar produtos de alta margem no carrinho, especificamente itens de churrasco.

4. Inteligência Artificial e Veredito (O Risco de R$ 225/dia)

Para quantificar o risco de ruptura de fluxo, implantamos um modelo preditivo de **Regressão Linear** (`scikit-learn`) focado em Elasticidade Cruzada da Demanda. **A Matemática do Chão de Loja:**

- A IA provou que a cada aumento no preço da cerveja, perdemos volume de Picanha.
- Cenário A (Cerveja a R$6,50): $Previsão de venda de 71 peças de Picanha (Lucro: R$ 1.775,00).
- Cenário B (Cerveja a R$7,20): $Fuga de clientes derruba a venda para 62 peças (Lucro: R$ 1.550,00).
- **O Rombo:** A diferença entre os cenários resultou em uma perda projetada de exatos **R$ 225,00 diários** (9 peças não vendidas x R$ 25,00 de lucro limpo por peça).

🎯 A Ordem Executiva

A etiqueta da Heineken LN deve ser mantida a R$ 6,50. O varejo não vive de margem percentual de cerveja; vive de Lucro Bruto Absoluto de carrinho. A estratégia de *Loss Leader* absorve o custo da indústria para proteger as centenas de reais geradas diariamente pelo açougue.